

Inteligencia Artificial Mecatronica

Clase 2: Vision de Proyecto y Regresion Lineal

Diego Stalder
dstalder@ing.una.py

Facultad de Ingenieria
Universidad Nacional de Asuncion


27 de Julio de 2026

- **Vision de Proyecto:** Pipeline de IA
- **El Problema Real:** California Housing
- Exploración de datos en el Notebook
- **Teoria:** Regresion Lineal
- Ecuacion Normal y su derivacion
- Formulacion Estadistica (MLE)
- Gradiente Descendente (GD) y SGD
- **Implementacion en vivo:** Desde cero con NumPy
- **Ejemplo:** Ventas con pandas y sklearn
- Analisis de Diagnostico: Residuos y VIF
- El problema de las escalas
- Normalizacion como solucion

Estrategia

Problema Real → Teoria → Demostración (Notebook)

Tengan el notebook abierto



Enfoque de la Clase

Nos enfocaremos en las etapas de **EDA**, **Preprocesamiento** y **Entrenamiento** usando Regresion Lineal.

Problema

Prediccion de precios de viviendas en California

Dataset:

- 20,640 muestras
- 8 características
- Variable objetivo: precio medio

Características:

- MedInc: Ingreso medio
- HouseAge: Edad media
- AveRooms: Prom. habitaciones
- Population: Poblacion
- Latitude, Longitude

El problema de escala:

Variable	Min	Max
MedInc	0.50	15.00
HouseAge	1.00	52.00
AveRooms	0.85	141.91
Population	3.00	35,682

Population varia en 4 ordenes de magnitud!

PAUSA PRACTICA - A CODIFICAR

Abran Google Colab y sigan la demostración

Demostración en vivo

- Importación de librerías esenciales (pandas, numpy, matplotlib, seaborn).
- Carga del dataset oficial usando `fetch_california_housing`.
- Inspección inicial de la estructura de datos (`head`, `describe`, `info`).

Observen en el notebook: Cada variable tiene un rango y escala diferentes

Análisis Gráfico en el Notebook

- Generación de histogramas para visualizar la distribución de cada característica.
- Creación de gráficos de dispersión (*scatter plots*) para observar la relación directa de cada variable contra el Precio objetivo.

¿Qué variable parece tener la relación más fuerte con el precio?

Mapa de Calor en el Notebook

- Cálculo matemático de la matriz de correlación de Pearson.
- Visualización térmica utilizando `seaborn.heatmap` para identificar relaciones de forma intuitiva.

Observaciones clave que discutiremos

- MedInc tiene correlacion ~ 0.69 con el precio
- AveRooms correlacion ~ 0.15 con el precio
- Population correlacion ~ -0.03 con el precio
- ¿Es esto cierto o es un artefacto de las escalas?

?Pregunta para la clase

Si queremos predecir el precio usando ingreso, numero de habitaciones y poblacion, ¿como cree que el modelo interpreta cada variable? ¿Tienen todas la misma importancia?

Modelo general:

$$\hat{y} = w_1x_1 + w_2x_2 + \cdots + w_dx_d + b$$

Forma vectorial:

$$\hat{y} = \mathbf{w}^T \mathbf{x} + b$$

Forma matricial (incluyendo bias en $\mathbf{w}$):

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1d} \\ 1 & x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & x_{N2} & \cdots & x_{Nd} \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} b \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}$$

Donde N = numero de muestras, d = numero de características.

Definicion:

$$J(\mathbf{w}) = \frac{1}{2N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 = \frac{1}{2N} \sum_{i=1}^N (y_i - \mathbf{x}_i^T \mathbf{w})^2$$

Forma matricial:

$$J(\mathbf{w}) = \frac{1}{2N} (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

Observacion

El factor $\frac{1}{2}$ se usa por conveniencia en la derivacion (cancela el 2 al derivar).

Objetivo: Encontrar $\mathbf{w}$ que minimiza $J(\mathbf{w})$.

Derivacion

Expandir la funcion de costo

$$J(\mathbf{w}) = \frac{1}{2N} (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

Expansion:

$$J(\mathbf{w}) = \frac{1}{2N} \left[\mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\mathbf{w} - (\mathbf{X}\mathbf{w})^T \mathbf{y} + (\mathbf{X}\mathbf{w})^T \mathbf{X}\mathbf{w} \right]$$

Simplificando (terminos escalares):

$$J(\mathbf{w}) = \frac{1}{2N} \left[\mathbf{y}^T \mathbf{y} - 2\mathbf{w}^T \mathbf{X}^T \mathbf{y} + \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} \right]$$

- $\mathbf{y}^T \mathbf{y}$: constante (no depende de $\mathbf{w}$)
- $-2\mathbf{w}^T \mathbf{X}^T \mathbf{y}$: lineal en $\mathbf{w}$
- $\mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w}$: cuadratico en $\mathbf{w}$

Derivacion

Calcular el gradiente $\nabla_{\mathbf{w}} J(\mathbf{w})$

Reglas de derivacion matricial:

- $\nabla_{\mathbf{w}}(\mathbf{w}^T \mathbf{a}) = \mathbf{a}$
- $\nabla_{\mathbf{w}}(\mathbf{w}^T \mathbf{A} \mathbf{w}) = 2\mathbf{A} \mathbf{w}$ (si $\mathbf{A}$ es simetrica)

Aplicando:

$$J(\mathbf{w}) = \frac{1}{2N} \left[\mathbf{y}^T \mathbf{y} - 2\mathbf{w}^T \mathbf{X}^T \mathbf{y} + \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} \right]$$

$$\nabla_{\mathbf{w}} J(\mathbf{w}) = \frac{1}{2N} \left[-2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \mathbf{w} \right] = \frac{1}{N} \left[-\mathbf{X}^T \mathbf{y} + \mathbf{X}^T \mathbf{X} \mathbf{w} \right]$$

Resultado intermedio

$$\nabla_{\mathbf{w}} J(\mathbf{w}) = \frac{1}{N} \left(\mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{X}^T \mathbf{y} \right)$$

Derivacion

Igualar el gradiente a cero y resolver

$$\nabla_{\mathbf{w}} J(\mathbf{w}) = 0$$

$$\frac{1}{N} (\mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{X}^T \mathbf{y}) = 0$$

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$$

Ecuacion Normal

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$$

Si $\mathbf{X}^T \mathbf{X}$ es invertible:

$$\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Verificacion: segunda derivada

$$\nabla^2 J(\mathbf{w}) = \frac{1}{N} \mathbf{X}^T \mathbf{X}$$

Suposicion fundamental:

$$y = \mathbf{x}^T \mathbf{w} + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

Interpretacion probabilistica:

$$p(y|\mathbf{x}, \mathbf{w}, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \mathbf{x}^T \mathbf{w})^2}{2\sigma^2}\right)$$

Significado

- y es una variable aleatoria con media $\mathbf{x}^T \mathbf{w}$
- El ruido ϵ es Gaussiano (Teorema Central del Limite)
- σ^2 es la varianza del ruido

Equivalencia: MSE = MLE

Derivacion

Maximizar ℓ equivale a minimizar el MSE

$$\ell(\mathbf{w}) = -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{x}_i^T \mathbf{w})^2$$

- Para σ^2 fijo, maximizar $\ell \Leftrightarrow$ minimizar $\sum (y_i - \mathbf{x}_i^T \mathbf{w})^2$
- Esto es exactamente el **MSE** (salvo constante $\frac{1}{N}$)

Conclusion clave

$$\hat{\mathbf{w}}_{\text{MLE}} = \hat{\mathbf{w}}_{\text{MSE}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Bajo ruido Gaussiano, MLE y MSE son equivalentes

Interpretacion

Minimizar MSE es estadisticamente optimo si el ruido es Gaussiano.

Algoritmo iterativo para minimizar $J(\mathbf{w})$:

Algorithm 1 Gradiente Descendente

- 1: Inicializar $\mathbf{w}^{(0)}$ (ej: $\mathbf{0}$)
 - 2: Definir $\eta > 0$ (tasa de aprendizaje)
 - 3: $t \leftarrow 0$
 - 4: **repeat**
 - 5: Calcular gradiente: $\nabla J(\mathbf{w}^{(t)}) = \frac{1}{N} \mathbf{X}^T (\mathbf{X} \mathbf{w}^{(t)} - \mathbf{y})$
 - 6: Actualizar: $\mathbf{w}^{(t+1)} \leftarrow \mathbf{w}^{(t)} - \eta \nabla J(\mathbf{w}^{(t)})$
 - 7: $t \leftarrow t + 1$
 - 8: **until** convergencia
-

Interpretacion geometrica

El gradiente apunta en la direccion de **maximo crecimiento**. Restamos el gradiente para movernos hacia el minimo.

PAUSA PRACTICA - A CODIFICAR

Pasemos al Notebook para aplicar estas ecuaciones

Implementación paso a paso

- Construcción de la matriz de diseño $\mathbf{X}$ agregando el sesgo (término constante).
- Resolución directa de la Ecuación Normal usando funciones de álgebra lineal.
- Alternativa matemática más estable: uso de la pseudoinversa de Moore-Penrose.

¿Qué sucede en el código cuando $\mathbf{X}^T \mathbf{X}$ no es invertible?

Ejemplo Práctico en el Notebook

- Generación de datos sintéticos con comportamiento no lineal.
- Creación artificial de características polinomiales (ej. X^2 , X^3).
- Ajuste del modelo sobre este nuevo espacio de características expandido.

¿Qué pasa con el ajuste si agregamos términos de mayor grado?

Demostración interactiva en el Notebook

- Configuración manual de hiperparámetros: tasa de aprendizaje (*learning rate*) e iteraciones.
- Construcción de un bucle de optimización: cálculo del gradiente y actualización iterativa de los pesos.
- Registro y graficado de la función de pérdida a lo largo del tiempo.

¿Cómo elegir adecuadamente la tasa de aprendizaje η ?

Uso de modelos optimizados (SGDRegressor)

- Instanciación de la clase SGDRegressor nativa de Scikit-learn.
- Entrenamiento rápido sobre los mismos datos sintéticos.
- Comparación de la métrica R^2 frente a nuestra implementación artesanal.

¿Cuál algoritmo de optimización converge más rápido? ¿GD o SGD?

Flujo de Trabajo en el Notebook

- Ingesta de un caso de negocio real (`Ventas.csv`) utilizando Pandas.
- Separación de las variables de inversión publicitaria y el retorno en ventas.
- División estricta de los datos en conjuntos de entrenamiento (*train*) y prueba (*test*).

Ajuste del Modelo

- Inicialización y entrenamiento de un objeto `LinearRegression`.
- Extracción automatizada de los coeficientes (pesos) y el intercepto.

Ecuacion teórica obtenida

$$\text{Sales} = 2,88 + 0,0466 \times \text{TV} + 0,179 \times \text{Radio} + 0,00345 \times \text{Newspaper}$$

¿Cómo interpretamos financieramente el coeficiente de TV (0.0466)?

Cálculos en el Notebook

- Generación de predicciones utilizando el conjunto de prueba aislado.
- Evaluación del desempeño utilizando métricas estándar importadas de `sklearn.metrics`.

Interpretación de Métricas

- **MAE**: Error absoluto promedio, fácil de interpretar.
- **MSE**: Penaliza exponencialmente los errores grandes.
- **RMSE**: Retorna la métrica a las mismas unidades que y .

Experimentación en vivo (Ver Notebook)

- **Caso Base:** Modelo con todas las variables incluidas (RMSE evaluado = 1.4047).
- **Iteración:** Reentrenamiento del modelo excluyendo la variable *Newspaper*.
- **Nuevo Resultado:** RMSE reducido a 1.3879.

Conclusion

- El RMSE **disminuyó** al eliminar la variable *Newspaper*.
- Esta métrica nos indica empíricamente que no aporta información útil para predecir ventas.
- Debería eliminarse del modelo definitivo.

Menor RMSE = Mejor capacidad predictiva

Definicion de Residuos

$$e_i = y_i - \hat{y}_i$$

- Diferencia exacta entre el valor observado real y nuestra predicción.
- Idealmente deben tener: media cero, distribucion normal y varianza constante (homocedasticidad).

Visualización en el Notebook

- Ploteo de un gráfico de dispersión de los residuos vs. los valores predichos.
- Construcción de un histograma para evaluar la normalidad de la distribución de los errores.

Problema

El numero de condicion de $X^T X$

$$\kappa(X^T X) = \frac{\lambda_{max}}{\lambda_{min}}$$

Análisis del Dataset California Housing en código

- Construiremos la matriz cruda y calcularemos su número de condición matemáticamente utilizando NumPy (`np.linalg.cond`).

Resultado Típico

Numero de condicion: 1.23e+15

- $\kappa \approx 10^{15}$ es un estado **pésimo**.
- La matriz $X^T X$ esta **casi singular**.
- Su inversion será **numericamente inestable**.

Problema

Cuando las variables predictoras están altamente correlacionadas entre sí

Factor de Inflación de la Varianza (VIF)

$$VIF_j = \frac{1}{1 - R_j^2}$$

- R_j^2 : coeficiente de determinación al regresar X_j contra todas las demás variables
- $VIF > 10$: síntoma de multicolinealidad severa
- Consecuencias prácticas: pesos inestables y errores estándar inflados.

Cálculo en el Notebook

- Utilizaremos la función `variance_inflation_factor` de la librería `statsmodels`.
- Generaremos un `DataFrame` resumen para evaluar el nivel de correlación de cada columna.

Solucion

Normalizar o estandarizar los datos numéricos antes de entrenar

Dos tecnicas matemáticas principales

1. Normalizacion (Min-Max):

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \in [0, 1]$$

2. Estandarizacion (Z-score):

$$x' = \frac{x - \mu}{\sigma}, \quad \mu = 0, \sigma = 1$$

Aplicación mediante Scikit-learn (Notebook)

- Instanciaremos los objetos `StandardScaler` o `MinMaxScaler`.
- Transformaremos las matrices crudas en espacios normalizados de forma eficiente.

¿Qué técnica de las dos es mejor usar para el dataset de California Housing?

Variable	Peso (crudo)	Peso (normalizado)
MedInc	0.438	0.438
HouseAge	0.009	0.112
AveRooms	-0.112	-0.108
Population	-0.000	-0.037
Latitude	-0.419	-0.820
Longitude	-0.431	-0.820

Interpretacion de pesos normalizados

- MedInc: $+0.438 \Rightarrow$ mas ingreso $\uparrow$ precio
- Latitude: $-0.820 \Rightarrow$ mas al norte $\downarrow$ precio
- Longitude: $-0.820 \Rightarrow$ mas al oeste $\downarrow$ precio
- ¡Ahora los pesos son directamente comparables en magnitud!

Quiz Rapido

Cual es el principal beneficio de normalizar los datos para la regresion lineal?

- (A) Reduce el numero de caracteristicas
- (B) Mejora la interpretabilidad de los pesos
- (C) Elimina los outliers
- (D) Hace que el modelo sea no lineal

Sin preprocesamiento

- $\kappa \gg 1$: Mal condicionado
- Convergencia lenta
- Pesos no interpretables
- Inestabilidad numerica
- Sensibilidad a outliers
- VIF alto: multicolinealidad

Con preprocesamiento

- $\kappa \approx 1$: Bien condicionado
- Convergencia rapida
- Pesos interpretables
- Estabilidad numerica
- Robustez a outliers
- VIF reducido: variables independientes

En una frase

El preprocesamiento transforma un problema numericamente inestable en uno estable e interpretable.

Regla de oro

Preprocesar siempre antes de entrenar cualquier modelo.

¿Preguntas? Sobre derivacion, MLE, GD, o los ejemplos practicos ¡Manos a la obra en Google Colab con el resto de los ejercicios!

Recuerden:
Preprocesar siempre antes de entrenar