

Regresión Logística

Clasificación Binaria, Entropía Cruzada e Interpretación

Diego Stalder

Curso de Machine Learning

August 5, 2026

Contenido General

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística
- 3 Función de Costo y Estimación (MLE)
- 4 Optimización y Regularización
- 5 Interpretación de Coeficientes
- 6 Flujo de Trabajo e Implementación
- 7 Resumen

Contenido

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística
- 3 Función de Costo y Estimación (MLE)
- 4 Optimización y Regularización
- 5 Interpretación de Coeficientes
- 6 Flujo de Trabajo e Implementación
- 7 Resumen

¿Qué es la Clasificación Binaria?

Objetivo del Modelo

Predecir una variable categórica objetivo de dos clases:

$$y \in \{0, 1\}$$

Ejemplos de Aplicación:

- Spam (1) vs. No spam (0)
- Diagnóstico: Enfermo (1) vs. Sano (0)
- Transacción: Fraudulenta (1) vs. Legítima (0)

¿Por qué NO usar Regresión Lineal?

Si ajustamos $y = \mathbf{w}^T \mathbf{x} + b$ mediante OLS:

- 1 Predice valores fuera del rango $[0, 1]$ (p. ej., $\hat{y} = 1.4$ o -0.2).
- 2 Sensible a valores atípicos (*outliers*).
- 3 No ofrece una interpretación probabilística válida.

Contenido

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística**
- 3 Función de Costo y Estimación (MLE)
- 4 Optimización y Regularización
- 5 Interpretación de Coeficientes
- 6 Flujo de Trabajo e Implementación
- 7 Resumen

La Función Sigmoide (Logística)

Definición Matemática

Mapea cualquier número real $z \in \mathbb{R}$ al intervalo $(0, 1)$:

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}$$

donde $z = \mathbf{w}^T \mathbf{x} + b$.

Propiedades Clave

- $\lim_{z \rightarrow \infty} \sigma(z) = 1$
- $\lim_{z \rightarrow -\infty} \sigma(z) = 0$
- $\sigma(0) = 0.5$ (Punto de inflexión)
- Derivada simétrica:
 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

Formulación Probabilística y Regla de Decisión

Modelado de Probabilidad

$$P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b) \quad y \quad P(y = 0|\mathbf{x}) = 1 - \sigma(\mathbf{w}^T \mathbf{x} + b)$$

Regla de Decisión (Umbral 0.5)

$$\hat{y} = \begin{cases} 1 & \text{si } P(y = 1|\mathbf{x}) \geq 0.5 \implies z \geq 0 \\ 0 & \text{en otro caso } (z < 0) \end{cases}$$

Frontera de Decisión

La frontera de decisión es el hiperplano donde $z = 0$:

$$\mathbf{w}^T \mathbf{x} + b = 0$$

Separa el espacio de características de forma **lineal**.

Contenido

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística
- 3 Función de Costo y Estimación (MLE)**
- 4 Optimización y Regularización
- 5 Interpretación de Coeficientes
- 6 Flujo de Trabajo e Implementación
- 7 Resumen

¿Por qué la Entropía Cruzada?

Problema del Error Cuadrático (MSE)

Combinar el MSE con la función sigmoide resulta en una superficie de costo **no convexa**.

- Presencia de múltiples mínimos locales.
- El Gradiente Descendente se puede estancar fácilmente.

Ventaja de Entropía Cruzada

Garantiza una función de costo **convexa** con un único mínimo global.

- Derivada del principio de Estimación de Máxima Verosimilitud (MLE).
- Penaliza fuertemente predicciones incorrectas con alta confianza.

Justificación por Máxima Verosimilitud (MLE)

- Para una observación $y_i \in \{0, 1\}$, la distribución de Bernoulli se expresa como:

$$P(y_i | \mathbf{x}_i) = p_i^{y_i} (1 - p_i)^{1-y_i}$$

- Asumiendo observaciones independientes, la **Función de Verosimilitud** conjunta es:

$$L(\mathbf{w}, b) = \prod_{i=1}^N p_i^{y_i} (1 - p_i)^{1-y_i}$$

- Aplicando el logaritmo natural obtenemos la **Log-Verosimilitud**:

$$\ell(\mathbf{w}, b) = \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

Entropía Cruzada Binaria (Log Loss)

Función de Costo Promedio $J(\mathbf{w}, b)$

Minimizar el costo equivale a maximizar la Log-Verosimilitud (negativa promediada):

$$J(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \right]$$

Análisis de la pérdida individual $\mathcal{L}_i$:

- Si $y_i = 1$: $\mathcal{L}_i = -\log(p_i)$. Si $p_i \rightarrow 1 \implies \mathcal{L}_i \rightarrow 0$. Si $p_i \rightarrow 0 \implies \mathcal{L}_i \rightarrow \infty$.
- Si $y_i = 0$: $\mathcal{L}_i = -\log(1 - p_i)$. Si $p_i \rightarrow 0 \implies \mathcal{L}_i \rightarrow 0$. Si $p_i \rightarrow 1 \implies \mathcal{L}_i \rightarrow \infty$.

Contenido

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística
- 3 Función de Costo y Estimación (MLE)
- 4 Optimización y Regularización**
- 5 Interpretación de Coeficientes
- 6 Flujo de Trabajo e Implementación
- 7 Resumen

Optimización: Gradiente Descendente

Derivadas Parciales de $J(\mathbf{w}, b)$

Gracias a la cancelación algebraica entre la sigmoide y el logaritmo:

$$\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i) \mathbf{x}_i, \quad \frac{\partial J}{\partial b} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)$$

Regla de Actualización de Parámetros

Con una tasa de aprendizaje $\alpha > 0$:

$$\mathbf{w} \leftarrow \mathbf{w} - \alpha \frac{\partial J}{\partial \mathbf{w}}, \quad b \leftarrow b - \alpha \frac{\partial J}{\partial b}$$

Prevención del Sobreajuste: Regularización

Para controlar la magnitud de los pesos y evitar el sobreajuste (*overfitting*):

Regularización L2 (Ridge)

$$J_{L2}(\mathbf{w}, b) = J(\mathbf{w}, b) + \frac{\lambda}{2N} \sum_{j=1}^d w_j^2$$

Penaliza coeficientes muy grandes; mantiene todas las variables en el modelo.

Regularización L1 (Lasso)

$$J_{L1}(\mathbf{w}, b) = J(\mathbf{w}, b) + \frac{\lambda}{N} \sum_{j=1}^d |w_j|$$

Promueve la esparsidad (reduce coeficientes a cero exacto, útil para selección de variables).

Contenido

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística
- 3 Función de Costo y Estimación (MLE)
- 4 Optimización y Regularización
- 5 Interpretación de Coeficientes**
- 6 Flujo de Trabajo e Implementación
- 7 Resumen

Odds y Log-Odds (Logit)

Odds (Razón de Probabilidades)

Mide qué tan más probable es que ocurra el evento $y = 1$ frente a $y = 0$:

$$\text{Odds} = \frac{P(y = 1|\mathbf{x})}{P(y = 0|\mathbf{x})} = \frac{p}{1 - p}$$

Log-Odds (Transformación Logit)

Aplicando logaritmo a la razón de probabilidades:

$$\log\left(\frac{p}{1 - p}\right) = \mathbf{w}^T \mathbf{x} + b$$

El modelo es lineal en el espacio de Log-Odds.

Interpretación del Coeficiente w_j

- **En Log-Odds:** w_j es el cambio directo en los log-odds por cada aumento unitario en x_j , manteniendo los demás constantes.
- **En Odds Ratio (OR):** Aplicando la exponencial e^{w_j} :

$$OR = e^{w_j} = \text{Factor multiplicativo en los Odds}$$

Variable	Coeficiente (w_j)	e^{w_j} (OR)	Interpretación Práctica
Edad (años)	0.05	1.051	Cada año incrementa los odds en +5.1%
Ingreso (\$)	0.0003	1.0003	Efecto práctico insignificante por unidad
Masculino	-0.20	0.819	Odds se reducen un 18.1% vs. Femenino

Contenido

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística
- 3 Función de Costo y Estimación (MLE)
- 4 Optimización y Regularización
- 5 Interpretación de Coeficientes
- 6 Flujo de Trabajo e Implementación**
- 7 Resumen

1. Implementación "From Scratch"

- Construir `'sigmoid(z)'`
- Calcular `'cost_function(w, b, X, y)'`
- Ciclo de `'gradient_descent(X, y, lr, epochs)'`

2. Con Scikit-Learn

- Uso de `'LogisticRegression(C=1.0, penalty='l2)'`
- Evaluar matriz de confusión.
- Métrica AUC-ROC y reporte de clasificación.

Contenido

- 1 Introducción a la Clasificación Binaria
- 2 El Modelo de Regresión Logística
- 3 Función de Costo y Estimación (MLE)
- 4 Optimización y Regularización
- 5 Interpretación de Coeficientes
- 6 Flujo de Trabajo e Implementación
- 7 Resumen**

- **Naturaleza Probabilística:** Transforma combinaciones lineales en probabilidades mediante la función sigmoide.
- **Optimización Eficiente:** La Entropía Cruzada es una función de costo convexa que penaliza fuertemente el error.
- **Interpretabilidad:** Coeficientes explicables mediante el exponente e^{w_j} (Odds Ratios).
- **Control de Complejidad:** Regularización L1/L2 accesible a través de parámetros como $C = 1/\lambda$.

¡Manos a la Obra!

Abrir el archivo:

`logistic_regression_notebook.ipynb`