

Clase 6: Representation Learning y Reducción de Dimensionalidad

Diego Stalder
dstalder@ing.una.py

Facultad de Ingeniería
Universidad Nacional de Asunción

26 de Agosto de 2026

Inteligencia Artificial - 2026
Ingeniería Mecatrónica

Agenda de la Clase (1/2)

Parte 1: Fundamentos

- ¿Qué es Representation Learning?
- La Maldición de la Dimensionalidad
- Reducción de Dimensionalidad

Parte 2: Métodos Lineales

- **PCA** (Principal Component Analysis)
- Matemáticas de PCA
- Aplicaciones y ejemplos

Parte 3: Métodos No Lineales

- **t-SNE** (t-Distributed Stochastic Neighbor Embedding)
- **UMAP** (Uniform Manifold Approximation and Projection)

Agenda de la Clase (2/2)

Parte 4: Embeddings

- **Word2Vec**
- **GloVe**
- **FastText**

Metodología de Trabajo

Teoría → Pausa Práctica → Notebook Jupyter

Parte 5: Aplicación

- Reducción en datos académicos
- Visualización de embeddings

¿Qué es Representation Learning?

Definición


Proceso de **aprender representaciones** de los datos que facilitan tareas posteriores.

Idea Clave

- En lugar de diseñar características manualmente...
- ...el modelo las aprende automáticamente.

Ejemplo: Imágenes

- **Manual:** Píxeles → Bordos → Formas
- **Aprendido:** Características jerárquicas



Beneficios

- Automatiza feature engineering
- Descubre patrones ocultos
- Mejora generalización

Reducción de Dimensionalidad

Definición


Reducir el número de variables preservando la información relevante.

Clasificación

- **Lineales:** PCA, LDA
- **No lineales:** t-SNE, UMAP, Autoencoders

Objetivos

Visualización (2D/3D), reducción de ruido y compresión de datos.



Trade-off

Pros: Eficiencia. **Contras:** Pérdida de información.

PCA - Principal Component Analysis

Concepto


Encuentra direcciones de **máxima varianza** en los datos.

Componentes Principales

- **PC1**: Máxima varianza.
- **PC2**: Ortogonal a PC1 con segunda máxima varianza.

Objetivo

Proyectar datos en menor dimensión reteniendo máxima información.



Interpretación

- Línea roja: **PC1** (máxima varianza)
- Línea verde: **PC2** (segunda dirección)

Estandarización y Covarianza

$$Z = \frac{X - \mu}{\sigma}, \quad \Sigma = \frac{1}{n-1} Z^T Z$$

Proyección y Varianza Explicada

$$Y = Z \cdot W, \quad \text{VE}_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i}$$

Autovalores y Autovectores

$$\Sigma v = \lambda v$$

- v : Autovectores (direcciones)
- λ : Autovalores (varianza)

Ejemplo: MNIST

- 784 dimensiones originales
- 50 PCs retienen $\sim 90\%$ de varianza

¡Manos a la obra con PCA!

Objetivos de la Práctica

- 1 Cargar datos de rendimiento académico
- 2 Aplicar PCA con scikit-learn
- 3 Visualizar los primeros 2 componentes y la varianza

Código Base

```
from sklearn.decomposition import PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=y)
```

Pausa Práctica: PCA (2/2)

Tiempo Estimado: 20-30 minutos

Código base disponible en el notebook de la clase.

Preguntas Guía

- ¿Cuánta varianza explican los primeros 2 componentes?
- ¿Cómo se separan o visualizan las clases?
- ¿Cuántos componentes se necesitan para alcanzar el 95% de varianza explicada?


t-SNE - Introducción

Concepto

Método **no lineal** que preserva relaciones y similitudes locales entre puntos.

Ventajas y Desventajas

- **Pro:** Excelente visualización local.
- **Contra:** No preserva distancias globales, costoso computacionalmente.



Comparación

PCA preserva varianza global; t-SNE preserva vecindarios locales.

Similitudes Espacio Original/Proyectado

$$p_{j|i} = \frac{\exp(-||x_i - x_j||^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-||x_i - x_k||^2 / 2\sigma_i^2)}$$

$$q_{ij} = \frac{(1 + ||y_i - y_j||^2)^{-1}}{\sum_{k \neq i} (1 + ||y_k - y_i||^2)^{-1}}$$

Distribución t-Student

Colas pesadas para mitigar el problema de hacinamiento (crowding problem).

Divergencia KL y Perplejidad

$$\mathcal{L} = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

$$\text{Perp}(P_i) = 2^{H(P_i)}$$

- Controla el tamaño efectivo del vecindario (típico: 5–50).

UMAP - Introducción

Concepto

Reducción de dimensionalidad basada en **teoría de variedades** y topología.

Comparativa de Métodos

Método	Velocidad	Global	Local
PCA	Rápido	Excelente	Regular
t-SNE	Lento	Regular	Excelente
UMAP	Rápido	Bueno	Excelente

Ventajas

Más rápido que t-SNE, escala mejor a grandes volúmenes y preserva mejor la estructura global.

Parámetros

`n_neighbors`, `min_dist`, `metric`.

¡Práctica con Métodos No Lineales!

Objetivos

- 1 Aplicar t-SNE variando perplejidad y UMAP cambiando `n_neighbors`
- 2 Comparar agrupaciones de estudiantes frente a PCA

Tiempo Estimado: 20-30 minutos

Código base en notebook.

Código Base

```
from sklearn.manifold import TSNE
from umap import UMAP

tsne = TSNE(n_components=2, perplexity=30)
X_tsne = tsne.fit_transform(X_scaled)

umap = UMAP(n_neighbors=15, min_dist=0.1)
```

Word Embeddings - Introducción

¿Qué son?


Vectorización de palabras en espacios continuos de baja dimensión.

Propiedades

Capturan relaciones semánticas mediante operaciones vectoriales.

Analogías Vectoriales

$$\vec{re\grave{y}} - \vec{hom\breve{b}re} + \vec{mu\breve{j}er} \approx \vec{re\breve{i}na}$$



Aplicaciones

NLP, traducción, búsqueda semántica y clasificación.

Arquitecturas

- **CBOW**: Predice palabra central dado el contexto.
- **Skip-gram**: Predice contexto dada la palabra central.

Objetivo

$$\mathcal{L} = - \sum_{i=1}^N \log P(w_i | \text{contexto})$$



GloVe

Modela frecuencias globales mediante matriz de coocurrencia.

$$\mathcal{L} = \sum_{i,j} f(X_{ij}) \left(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2$$

FastText

Divide palabras en n -gramas de subpalabras:

$$\vec{w} = \sum_{g \in G_w} \vec{v}_g$$

Maneja palabras fuera del vocabulario (OOV).

¡Practicando con Embeddings!

Objetivos

Generar embeddings con Word2Vec (Gensim), explorar analogías y comparar con otros modelos.

Tiempo Estimado: 25-35 minutos

Código base en notebook.

Código Base

```
from gensim.models import Word2Vec

model = Word2Vec(sentences, vector_size=100, window=5)
vectors = model.wv['palabra']
model.wv.most_similar('rey')
```

Aplicación: Rendimiento Académico

Objetivo

Visualizar patrones y clusters en datos de estudiantes.

Variables Evaluadas


Notas parciales, prácticas, convocatorias y estado final.

Estrategia

Proyectar variables académicas mediante PCA, t-SNE y UMAP para identificar agrupaciones.

Resumen Comparativo

- **PCA:** Estructura lineal y tendencial global.
- **t-SNE:** Excelente separación de clusters locales.
- **UMAP:** Balance óptimo global/local.



Lo que viene

- 1 Aplicar reducción de dimensionalidad a datos reales.
- 2 Usar PCA como preprocesamiento para modelos de clasificación.
- 3 Visualizar clusters de asignaturas y estudiantes.

Entregable Final

Notebook Jupyter con implementaciones de PCA, t-SNE, UMAP y análisis comparativo.

Conclusiones Clave

- Representation Learning automatiza la extracción de características.
- La reducción de dimensionalidad mitiga la maldición de la dimensionalidad.
- PCA destaca en globalidad/linealidad, mientras que t-SNE y UMAP capturan relaciones no lineales complejas.
- Los Word Embeddings permiten operar semánticamente con texto.

Referencias y Recursos (1/2)

Libros de Texto

- Géron, A. (2019). *Hands-On Machine Learning*. O'Reilly.
- Goodfellow, I. (2016). *Deep Learning*. MIT Press.
- Hastie, T. (2009). *The Elements of Statistical Learning*. Springer.

Papers Fundamentales

- Van der Maaten, L. (2008). *Visualizing Data using t-SNE*. JMLR.
- McInnes, L. (2018). *UMAP: Uniform Manifold Approximation*. ArXiv.

Referencias y Recursos (2/2)

Papers de Embeddings

- Mikolov, T. (2013). *Efficient Estimation of Word Representations*. ArXiv.
- Pennington, J. (2014). *GloVe: Global Vectors for Word Representation*. EMNLP.
- Bojanowski, P. (2017). *Enriching Word Vectors with Subword Information*. ArXiv.

Bibliotecas Utilizadas

scikit-learn, umap-learn, gensim.

¿Preguntas?

¿Qué método consideran más adecuado para sus proyectos?

Material Adicional

- Notebook: `clase6_representation_learning.ipynb`
- Visualizador TensorFlow: <https://projector.tensorflow.org/>